Este informe ejecutivo presenta un análisis comparativo (**benchmarking**) de modelos de **Inteligencia Artificial (IA)** y **Visión por Computadora** optimizados para la detección de plagas y enfermedades en el cultivo de arroz. El enfoque principal es la viabilidad técnica en dispositivos móviles de gama de entrada y el funcionamiento **offline** para entornos rurales.

1. Resumen de Selección

Para lograr un equilibrio entre precisión y eficiencia en hardware limitado ($\le$ 4GB de RAM), se han priorizado arquitecturas ligeras que permiten inferencia en tiempo real sin conexión a internet mediante conversiones a **TensorFlow Lite** o **NCNN**.

2. Comparación de Modelos (Benchmarking)

A continuación, se comparan los modelos con mejor desempeño reportado en la literatura científica reciente (2018-2025):

Modelo	Arquitectura Base	Precisión / mAP	Parámetros (M)	Velocidad / Latencia	Soporte Offline
YOLOv4-tiny	YOLO (Tiny variant)	**97.36% mAP**	~6.0	~5 ms/imagen	Sí (TFLite)
Improved YOLOv5s	YOLO + Ghost Module	**96.1% mAP**	3.9 (↓47.5%)	374 ms/frame	Sí (NCNN)
LiSA-MobileNetV2	MobileNetV2+Attention	**95.7% Acc**	~2.0	High (30+ FPS)	Sí (TFLite)
GBiDC-PEST	YOLO + GhostNet	80.1% mAP	**1.2 (2.8 MB)**	**161.3 FPS**	Sí (Android)
EfficientNet-B0	EfficientNet	96%+ Acc	5.3	25+ FPS	Sí (TFLite)
Simple CNN	Custom Lightweight	93.3% Acc	**0.8**	Ultra-fast	Sí

3. Ventajas y Limitaciones

Ventajas Principales

- **Eficiencia en el borde (Edge Computing):** El uso de **convoluciones separables en profundidad** (MobileNet) y **módulos Ghost** reduce el costo computacional entre un 50% y 75% comparado con modelos estándar como ResNet50.
- **Operación Offline:** Todos los modelos seleccionados son compatibles con marcos de optimización que eliminan la dependencia de la nube, vital en zonas rurales con baja conectividad.
- **Detección Multi-clase:** Las variantes YOLO permiten localizar múltiples plagas simultáneamente en una sola imagen, ideal para diagnósticos rápidos en campo.

Limitaciones Técnicas

- **Compromiso Precisión-Velocidad:** Los modelos más pequeños pueden sacrificar entre un 1% y 5% de precisión global para ganar fluidez.
- **Complejidad del Escenario:** La precisión tiende a disminuir (5-10%) ante condiciones de iluminación variable, fondos complejos o plagas muy pequeñas.
- **Efecto de Escala:** Los sistemas que intentan cubrir más de 12 clases de enfermedades ven una caída drástica en el mAP (hasta ~69%) debido a la similitud visual entre síntomas.

4. Propuestas Seleccionadas y Justificación Técnica

Basado en el análisis, se recomiendan las siguientes dos propuestas para integración en aplicaciones móviles y gafas de **Realidad Aumentada (RA)**:

Propuesta A: YOLOv4-tiny (Detección de Objetos)

- **Justificación:** Presenta el mejor balance de velocidad (~5ms) y precisión (97.36% mAP) para identificar y localizar plagas específicas en tiempo real. Su bajo conteo de parámetros permite que corra en dispositivos con procesadores Snapdragon de serie 6xx sin sobrecalentamiento.

Propuesta B: LiSA-MobileNetV2 (Clasificación de Enfermedades)

- **Justificación:** Seleccionado por su eficiencia extrema de memoria (reducción del 74% en uso de RAM) y el uso de **mecanismos de atención**, que elevan la precisión en hojas con síntomas tempranos. Es ideal para funcionar como motor de clasificación detrás de la interfaz de RA.

5. Recomendaciones de Implementación

1. **Cuantización:** Aplicar técnicas de cuantización **INT8** durante la conversión a TFLite para reducir el tamaño del modelo a menos de 15MB, asegurando compatibilidad con móviles de gama de entrada.
2. **Enfoque Específico:** Limitar el alcance inicial a las **3-6 enfermedades más críticas** (ej. añublo, mancha marrón, piricularia) para garantizar una precisión superior al 95%.
3. **Interfaz de Voz:** Dado que se planea usar con gafas de RA, se sugiere integrar los modelos con un chatbot offline para comandos de voz, simplificando la tarea del agricultor en campo.

Este informe ejecutivo presenta un análisis comparativo (**benchmarking**) de modelos de **Inteligencia Artificial (IA)** y **Visión por Computadora** para la detección de enfermedades y plagas en el cultivo de arroz, diseñado específicamente para operar de forma **offline** en dispositivos móviles de gama de entrada y gafas de **Realidad Aumentada (RA)** en el departamento del Meta, Colombia.

1. Comparación de Modelos (Benchmarking)

El análisis se centra en modelos publicados entre 2016 y 2026 que cumplen con restricciones de hardware ($\le$ 4GB de RAM) y alta eficiencia computacional.

Modelo	Arquitectura Base	Precisión / mAP	Tamaño / Parámetros	Velocidad (Inferencia)	Soporte Offline
YOLOv4-tiny	YOLO (Tiny)	**97.36% mAP**	~6.0M	**~5 ms/imagen**	Sí (TFLite)
Improved YOLOv5s	GhostNet + YOLOv5	**96.1% mAP**	3.9M (↓47.5%)	374 ms/frame	Sí (NCNN)
LiSA-MobileNetV2	MobileNetV2 + Attn	95.7% Acc	~2.0M	30+ FPS	Sí (TFLite)
GBiDC-PEST	YOLO + GhostNet	80.1% mAP	**2.8 MB (Ultra)**	**161.3 FPS**	Sí (Android)
SSD-YOLO	YOLOv8 + SENet	98.99% Acc	6.0M	Alta	Sí (Android)
Simple CNN	Custom Lightweight	93.3% Acc	**0.8M**	Muy Rápida	Sí
EfficientNet-B0	EfficientNet	96%+ Acc	5.3M	25+ FPS	Sí (TFLite)
YOLOv8nano	YOLOv8	~95% mAP	3.2M	30+ FPS	Sí

---

2. Ventajas y Limitaciones Técnicas

Ventajas Principales

- **Eficiencia en el Borde:** El uso de **módulos Ghost** y **convoluciones separables** reduce el costo computacional entre un 50% y 75% comparado con modelos pesados como ResNet50.
- **Operación Sin Internet:** La conversión a formatos **TensorFlow Lite (TFLite)**, **NCNN** o **MNN** permite que el procesamiento ocurra localmente en el dispositivo, eliminando la dependencia de la nube en áreas rurales.
- **Mecanismos de Atención:** La integración de módulos como **CBAM** o **SENet** mejora la detección en condiciones de fondo complejo (hojas de arroz con barro o maleza).

Limitaciones Identificadas

- **Complejidad Multi-clase:** Sistemas que intentan detectar más de 12 clases simultáneamente ven caer su precisión hasta un **69% mAP**, debido a la similitud visual entre síntomas.
- **Hardware de Entrada:** Los modelos que exceden los **15MB** de tamaño o los **300MB** de uso de RAM pueden causar sobrecalentamiento o cierres inesperados en móviles básicos.
- **Variabilidad Ambiental:** La detección de plagas diminutas puede fallar bajo condiciones de iluminación extrema o si el síntoma es muy temprano.

3. Justificación Técnica y Propuestas Seleccionadas

Basado en la necesidad de desplegar en **gafas de RA** y móviles Android en el Meta, se seleccionan las siguientes propuestas:

- **Propuesta A: YOLOv4-tiny (Detección de Objetos).** Es la mejor opción para identificar plagas en tiempo real debido a su latencia ultra-baja (~5ms) y precisión superior al 97% en sets de 3-6 enfermedades críticas.
- **Propuesta B: LiSA-MobileNetV2 (Clasificación).** Justificada por su reducción del **74% en uso de memoria** y su arquitectura optimizada para smartphones, ideal para ser integrada con el chatbot de asistencia personalizada.
- **Propuesta C: Simple CNN (Eficiencia Extrema).** Seleccionada como respaldo para dispositivos con recursos críticos, al ser un **99% más pequeña** que modelos tradicionales como VGG16.

4. Fuentes Bibliográficas y Científicas

Este informe extrae información de los siguientes estudios y repositorios (2016-2025):

1. **Deng, J., et al. (2023):** "Deep-Learning-Based Rice Disease and Insect Pest Detection on a Mobile Phone." *Agronomy*..
2. **Rahman, C. R., et al. (2018):** "Identification and Recognition of Rice Diseases and Pests Using CNN." *Biosystems Engineering*..
3. **Khanal, B., et al. (2024):** "Paddy Disease Detection and Classification Using Computer Vision Techniques." *arXiv*..
4. **Su, Q., et al. (2024):** "GBiDC-PEST: A novel lightweight model for real-time multiclass tiny pest detection." *Journal of Integrative Agriculture*..

5. **Jain, S., et al. (2022):** "Automatic Rice Disease Detection and Assistance Framework Using Deep Learning and a Chatbot." *Electronics*..
6. **Nayak, A., et al. (2023):** "Application of Smartphone-Image Processing for Rice Disease Detection." *Smart Agricultural Technology*..
7. **Hasan, M. M., et al. (2023):** "Enhancing Rice Crop Management: Disease Classification Using CNN." *Agriculture*..
8. **Pan, C., et al. (2024):** "SSD-YOLO: a lightweight network for rice leaf disease detection." *Frontiers in Plant Science*..
9. **DOD (Decision Records):** Documentación técnica de conversión a TFLite y NCNN para modelos de arroz.
10. **Repositorios de Modelos:** Hugging Face (allenai) y bibliografía de IEEE/arXiv (2020-2024).