INFORME EJECUTIVO

Proyecto: Sistema de Realidad Aumentada (RA) e Inteligencia Artificial (IA) para la Gestión de Plagas, Enfermedades y Pesticidas en el Cultivo de Arroz en el Meta, Colombia
Autor: Julio Vargas-Riaño
Fecha: Febrero 2026

.

1. Resumen Ejecutivo

Este informe presenta un análisis integral y comparativo (benchmarking) de modelos de Inteligencia Artificial (IA) y Visión por Computadora orientados a la detección automática de plagas y enfermedades en el cultivo de arroz, con énfasis en la viabilidad técnica para dispositivos móviles de gama de entrada y gafas de Realidad Aumentada (RA), bajo condiciones de operación **offline** en zonas rurales del departamento del Meta, Colombia.

El estudio integra evidencia científica publicada entre 2016 y 2025, así como documentación técnica y pruebas de campo, con el objetivo de identificar las arquitecturas más eficientes en términos de **precisión, latencia, consumo de memoria y escalabilidad**. Como resultado, se proponen arquitecturas híbridas que combinan modelos de detección y clasificación optimizados, permitiendo diagnósticos rápidos, precisos y accesibles para agricultores y técnicos agrícolas.

.

2. Objetivos del Proyecto

Objetivo General

Desarrollar e implementar un sistema inteligente basado en IA y RA que permita la **detección temprana, clasificación y gestión de plagas y enfermedades del arroz**, facilitando la toma de decisiones agronómicas en tiempo real y reduciendo el uso ineficiente de pesticidas.

Objetivos Específicos

- Evaluar modelos de visión por computadora de alto desempeño bajo restricciones de hardware.
- Identificar arquitecturas ligeras aptas para operación offline.
- Integrar los modelos seleccionados en una plataforma móvil con soporte de RA.
- Optimizar la experiencia del usuario mediante interfaces visuales y comandos de voz.
- Validar el impacto del sistema en productividad, sostenibilidad y reducción de costos.

.

3. Metodología de Benchmarking

El benchmarking se desarrolló en cuatro etapas:

1. **Revisión sistemática de literatura científica** (2016–2025) en bases de datos IEEE, ScienceDirect, Springer, MDPI, Frontiers y arXiv.
2. **Evaluación técnica de arquitecturas deep learning**, priorizando modelos ligeros (≤ 6M parámetros).
3. **Comparación experimental** de precisión (Accuracy, mAP), latencia, consumo de memoria y compatibilidad con TensorFlow Lite (TFLite) y NCNN.
4. **Análisis de viabilidad de implementación** en dispositivos Android y gafas RA.

.

4. Comparación de Modelos (Benchmarking)

Modelo	Arquitectura Base	Precisión / mAP	Parámetros	Velocidad	Soporte Offline
YOLOv4-tiny	YOLO Tiny	97.36% mAP	~6.0M	~5 ms/img	Sí (TFLite)
Improved YOLOv5s	YOLO + Ghost	96.1% mAP	3.9M	374 ms/frame	Sí (NCNN)
LiSA-MobileNetV2	MobileNetV2 + Atención	95.7% Acc	~2.0M	30+ FPS	Sí (TFLite)
GBiDC-PEST	YOLO + GhostNet	80.1% mAP	1.2M	161 FPS	Sí
EfficientNet-B0	EfficientNet	96%+ Acc	5.3M	25+ FPS	Sí (TFLite)
SSD-YOLO	YOLOv8 + SENet	98.99% Acc	~6.0M	Alta	Sí
Simple CNN	CNN ligera	93.3% Acc	0.8M	Ultra rápida	Sí
YOLOv8nano	YOLOv8	~95% mAP	3.2M	30+ FPS	Sí

.

5. Análisis Técnico

Ventajas Principales

- **Eficiencia en el borde (Edge Computing):** Reducción del costo computacional entre 50–75% frente a modelos tradicionales (ResNet, VGG).
- **Operación Offline:** Procesamiento local sin dependencia de conectividad, ideal para zonas rurales.
- **Detección Multiclase:** Capacidad de identificar múltiples plagas en una sola imagen.
- **Integración con RA:** Visualización directa de resultados sobre el entorno real.

Limitaciones Identificadas

- **Compromiso precisión–velocidad:** Modelos más pequeños sacrifican entre 1–5% de precisión.

- **Variabilidad ambiental:** Reducción del desempeño ante baja iluminación, fondos complejos o síntomas tempranos.
- **Escalabilidad multiclase:** La precisión cae drásticamente al exceder 12 clases simultáneas.

.

6. Propuestas Técnicas Seleccionadas

Propuesta A – YOLOv4-tiny (Detección)

- **Función:** Localización de plagas en tiempo real.
- **Ventajas:** 97.36% mAP, latencia ~5 ms, bajo consumo de memoria.
- **Aplicación:** Detección visual directa mediante RA.

Propuesta B – LiSA-MobileNetV2 (Clasificación)

- **Función:** Clasificación fina de enfermedades foliares.
- **Ventajas:** 74% de reducción de uso de memoria, alta precisión en síntomas tempranos.
- **Aplicación:** Soporte diagnóstico para recomendaciones agronómicas.

Propuesta C – CNN Ligera (Respaldo)

- **Función:** Operación en hardware extremadamente limitado.
- **Ventajas:** Tamaño ultra reducido, máxima velocidad.

.

7. Arquitectura General del Sistema

1. Captura de imágenes mediante cámara móvil o gafas RA.
2. Preprocesamiento local.
3. Detección con YOLOv4-tiny.
4. Clasificación con LiSA-MobileNetV2.
5. Visualización en RA y generación de alertas.
6. Recomendaciones agronómicas con chatbot offline.

.

8. Impacto Esperado

- Reducción del **30–45% en el uso de pesticidas**.
- Incremento del **10–25% en el rendimiento del cultivo**.
- Disminución significativa de pérdidas económicas.
- Mejora en la sostenibilidad ambiental y salud del agricultor.

.

9. Recomendaciones de Implementación

1. Aplicar **cuantización INT8** para reducir tamaño de modelos (<15MB).
2. Limitar la detección inicial a **3–6 enfermedades críticas**.
3. Integrar **interfaz de voz offline** para uso con gafas RA.
4. Implementar actualización modular de modelos.
5. Capacitar a técnicos y agricultores.

.

10. Fuentes Bibliográficas y Científicas

1. Deng, J. et al. (2023). *Deep-Learning-Based Rice Disease and Insect Pest Detection on a Mobile Phone*. Agronomy.
2. Rahman, C. R. et al. (2018). *Identification and Recognition of Rice Diseases and Pests Using CNN*. Biosystems Engineering.
3. Khanal, B. et al. (2024). *Paddy Disease Detection and Classification Using Computer Vision Techniques*. arXiv.
4. Su, Q. et al. (2024). *GBiDC-PEST: A Novel Lightweight Model for Tiny Pest Detection*. Journal of Integrative Agriculture.
5. Jain, S. et al. (2022). *Automatic Rice Disease Detection and Assistance Framework Using Deep Learning and a Chatbot*. Electronics.
6. Nayak, A. et al. (2023). *Application of Smartphone-Image Processing for Rice Disease Detection*. Smart Agricultural Technology.
7. Hasan, M. M. et al. (2023). *Enhancing Rice Crop Management: Disease Classification Using CNN*. Agriculture.
8. Pan, C. et al. (2024). *SSD-YOLO: A Lightweight Network for Rice Leaf Disease Detection*. Frontiers in Plant Science.
9. Documentación técnica TensorFlow Lite y NCNN.
10. Repositorios de modelos: HuggingFace, GitHub, IEEE Xplore, arXiv.

.

11. Conclusión Ejecutiva

La integración de Inteligencia Artificial ligera con Realidad Aumentada representa una **solución tecnológica viable, escalable y sostenible** para la gestión fitosanitaria del cultivo de arroz en Colombia. La propuesta ofrece un alto impacto socioeconómico y ambiental, alineándose con los principios de la **Agricultura 4.0 y el desarrollo rural inteligente**.